

Identificação de Modelos de Nível em uma Planta Didática Industrial

Rafael F. Felix^{*}, Wendy Y. E. Herrera^{*}

^{*} Departamento de Engenharia Elétrica, Instituto de Ciências Exatas e Aplicadas, Universidade Federal de Ouro Preto — UFOP, 35931-008, João Monlevade, MG, Brasil (e-mails: rafael.felix@aluno.ufop.edu.br, wendy.herrera@ufop.edu.br).

Abstract: This work investigates the problem of mathematical modeling for the level system in industrial tanks. The trials were conducted using the didactic plant SMAR PD3-F. The methodology of this work employs system identification techniques for black-box models. From experimental trials, linear Autoregressive with Exogenous Inputs (ARX) and nonlinear Autoregressive with Exogenous Inputs (NARX) models are obtained, describing the behavior of the level system. The results suggest that the NARX model provides a better characterization of the level plant dynamics. The NARX and ARX models achieved RMSE index values of 0.197 and 0.216, respectively.

Resumo: Este trabalho investiga o problema de modelagem matemática para o sistema de nível em tanques industriais. Os ensaios foram realizados utilizando a planta didática SMAR PD3-F. A metodologia deste trabalho utiliza técnicas de identificação de sistema para modelos do tipo caixa preta. A partir de ensaios experimentais, são obtidos modelos lineares Autorregressivo com Entradas Exógenas (ARX) e Não lineares Autorregressivo com Entradas Exógenas (NARX) que descrevem o comportamento do sistema de nível. Os resultados obtidos sugerem que o modelo NARX apresenta uma maior caracterização da dinâmica da planta de nível. Os modelos NARX e ARX alcançaram valores do índice RMSE de 0,197 e 0,216, respectivamente.

Keywords: Level; Industrial Didactic Plant; Systems Identification; Black Box Modeling; ARX model; NARX model.

Palavras-chaves: Nível; Planta Didática Industrial; Identificação de Sistemas; Modelagem Caixa-Preta; Modelo ARX; Modelo NARX.

1. INTRODUÇÃO

A modelagem matemática de um sistema dinâmico pode ser descrita como a tentativa de descrever matematicamente um fenômeno. Várias técnicas tem sido utilizadas na literatura para obter modelos matemáticos de um sistema dinâmico, como a modelagem caixa branca, modelagem caixa preta e modelagem caixa cinza (Aguirre, 2004). A modelagem caixa branca é aplicada nos casos em que é possível obter o modelo do sistema através da física ou natureza do processo como, por exemplo, sistemas massa-mola e circuitos RLC (Mombello et al., 2020). A modelagem caixa preta é utilizada quando têm-se disponíveis somente os sinais de entrada e saída do sistema. Essa modelagem utiliza técnicas que descrevem o comportamento do sistema sem considerar a estrutura interna do sistema. Por exemplo, Murray and Clarke (1995) propõe a modelagem de caixa preta do sistema de água subglacial. Na modelagem em caixa cinza ocorre uma combinação das técnicas utilizadas nas modelagens caixa branca e caixa preta, por exemplo, o estudo desenvolvido por Pereira and Munareto (2019) trata a modelagem caixa cinza para um circuito RC. A modelagem caixa preta é bastante utilizada

na literatura por não necessitar de conhecimento prévio do sistema abordado, tornando seu uso mais simples em comparação com as modelagens caixa branca e cinza. Para obter modelos do tipo caixa preta pode ser utilizado o processo de identificação de sistemas que consiste em cinco etapas: testes dinâmicos e coleta de dados, escolha da representação matemática, determinação da estrutura do modelo, estimação dos parâmetros e validação de modelos (Aguirre, 2004).

Um exemplo de um sistema dinâmico que pode ser tratado como um problema de modelagem matemática é a planta didática SMAR PD3-F. Essa planta didática permite a configuração de diversas malhas de controle para as variáveis de nível, temperatura e pressão. Entretanto, as medições destas variáveis podem apresentar uma perda de precisão devido ao desgaste dos equipamentos e instrumentos e a falta de manutenção na planta. Dessa forma, a modelagem matemática torna-se uma possibilidade para obter um modelo que represente a variável de estudo desejada, sendo possível compreender e validar o comportamento desta.

Existem vários trabalhos na literatura que tratam o problema de modelagem matemática da variável de nível na planta didática SMAR PD3-F, apresentando abordagens que utilizam de metodologias baseadas em redes neurais

^{*} O presente trabalho foi realizado com apoio da Universidade Federal de Ouro Preto (UFOP).

(Lopes et al., 2012) e blocos interconectados (Verly et al., 2019). Estudos desenvolvidos por (Lopes et al., 2012) apresentam a identificação de um sistema dinâmico assimétrico por meio de redes neurais utilizando uma arquitetura *feed-forward*, assim a partir do protocolo desenvolvido é realizado o treinamento da rede neural de forma que seja possível representar o modelo de uma planta didática de nível. Alternativamente, Verly et al. (2019) utiliza a modelagem caixa preta e cinza para estimar modelos para o sistema de nível de uma planta didática. Ao realizar a modelagem caixa preta é utilizado o processo de identificação de sistemas descrito em Aguirre (2004). Os autores utilizaram as representações Autorregressivo com Entradas Exógenas (ARX) para modelos lineares, para as representações não lineares os modelos não lineares Autorregressivo com Entradas Exógenas (NARX) e os modelos de Hammerstein e de Wiener. Os resultados evidenciam um melhor desempenho dos modelos não lineares ao representar a variável de nível.

Neste trabalho, investiga-se o problema de modelagem matemática para o sistema de nível na planta didática SMAR PD3-F utilizando técnicas de identificação de sistema para a modelagem caixa preta a partir de dados coletados nesta planta localizada no laboratório de Controle e Automação do Instituto de Ciências Exatas e Aplicadas - ICEA/UFOP. Nos últimos anos, durante ensaios experimentais desenvolvidos na planta didática SMAR PD3-F, constatou-se que alguns dispositivos de medição perderam sua precisão devido ao desgaste de peças e componentes, e a falta de manutenção. Para tentar contornar esse problema, propõe-se uma variação na configuração da planta didática e o uso de sinais de referência distintos aos utilizados em (Verly et al., 2019). Esse estudo utilizou uma configuração alternativa na planta didática PD3-F (veja Figura 1), cuja bomba monofásica (BM) é utilizada para bombear a água do reservatório (RA) até o tanque de aquecimento (T1). A abertura da válvula pneumática (FY), variável de entrada, determina a vazão de entrada (FIT) e consequentemente o nível de água no tanque T1, variável de saída. No presente trabalho, a configuração proposta considera que a bomba trifásica (BT) realiza o bombeamento da água do reservatório (RA) ao tanque de aquecimento (T1). O sinal de referência é aplicado no inversor de frequência (IF) que controla a bomba trifásica (BT), alterando a vazão de entrada (variável de entrada) e consequentemente o nível de água (variável de saída) no tanque de aquecimento (T1). A metodologia proposta utiliza sinais de entrada, u_k , e saída, y_k , para obter os modelos ARX e NARX que descrevem o comportamento do sistema de nível. Para validar esses modelos identificados, utilizam-se duas métricas: a simulação livre e o índice RMSE (do inglês, *Root Mean Square Error*).

2. MATERIAIS E MÉTODOS

2.1 Descrição da Planta Didática SMAR

A Planta Didática SMAR PD3-F visa demonstrar de forma didática o funcionamento das diversas malhas de controle usando os mesmos equipamentos e ferramentas de configuração de software utilizados na indústria (Smar, 2015). A planta didática possibilita a construção de diversas malhas de controle sem a necessidade de alterá-la fisicamente,




Figura 1. Configuração da planta didática utilizando a malha de controle 31, sendo os equipamentos utilizados no atual protocolo destacados em verde e os não utilizados em cinza.

sendo necessário apenas ajustar a configuração dos equipamentos, possibilitando simular e observar o comportamento de variáveis importantes para um determinado sistema dinâmico.

A planta didática PD3-F possui duas malhas de controle em sua composição, a malha de controle 31 e 32. Na Figura 1 mostra-se a malha de controle 31 responsável por controlar a variável de nível e a temperatura do tanque de aquecimento. Já a malha de controle 32 é utilizada para realizar a mistura de fluidos no tanque de mistura (Smar, 2015). Destaca-se que ambos os tanques de aquecimento e mistura possuem um formato cilíndrico. Neste trabalho, utiliza-se a malha de controle 31 analisando somente o comportamento da variável de nível. Na Tabela 1, indicam-se os componentes presentes na malha de controle 31. Na Figura 1 mostra-se um diagrama esquemático da planta didática SMAR. Esse diagrama destaca em verde o caminho percorrido pelo fluxo de água na planta e os equipamentos utilizados no atual protocolo experimental. Inicialmente a água sai do reservatório de água (RA) sendo bombeada pela bomba trifásica (BT) percorrendo duas válvulas manuais (VM) até encontrar o transmissor indicador de nível (FIT). Logo após, o fluxo de água passa por um conjunto de válvulas manuais e uma válvula pneumática (FY) para então alcançar o tanque de aquecimento (T1) e depois retornar ao reservatório de água.

Tabela 1. Componentes presentes na malha de controle 31.

Variáveis	Significado
VM	Válvulas Manuais
FY	Válvula Pneumática
BM	Bomba Monofásica
BT	Bomba Trifásica
RA	Reservatório de Água
T1	Tanque De Aquecimento
T2	Tanque De Mistura
FIT	Transmissor Indicador De Vazão
LIT	Transmissor Indicador De Nível
IF	Inversor De Frequência
SM	Software MATLAB

2.2 Identificação de Sistemas

O processo de identificação descrito por Aguirre (2004) apresenta como é possível obter representações matemáticas lineares e não lineares que possibilitem descrever sistemas dinâmicos utilizando somente sinais de entrada e saída usando a modelagem do tipo caixa preta. Este processo é composto por cinco etapas sequenciais: testes dinâmicos e coleta de dados, escolha da representação matemática, determinação da estrutura do modelo, estimação dos parâmetros e validação de modelos.

Testes dinâmicos e coleta de dados A etapa de testes dinâmicos consiste na obtenção de dados do sistema. Esses dados são obtidos a partir da operação padrão do sistema e de testes realizados para observar o comportamento do sistema de forma dinâmica. A escolha dos dados de entrada e saída considera a relação dinâmica das variáveis de vazão de entrada e o nível no tanque de aquecimento, visto que estas possuem uma correlação significativa. Além disso, nesta etapa são escolhidos os sinais persistentemente excitantes de entrada. Existem vários sinais que podem ser utilizados para a excitação do sistema como sinais pseudoaleatórios do tipo PRBS (do inglês *Pseudo Random Binary Signal*), sinais completamente aleatórios do tipo ruído branco, sinais senoidais, entre outros. Neste trabalho, utiliza-se sinais senoidais para excitar o sistema devido a sua capacidade de avaliar a estabilidade de sistemas e sendo amplamente utilizados para estimar parâmetros de sistemas (Ljung, 1998).

Escolha da representação matemática A escolha da representação depende de alguns fatores como as características do processo, a correlação dos dados de entrada e de saída do sistema, a aplicação do modelo matemático, entre outras. Neste trabalho, escolhem-se o modelo ARX para representar os modelos lineares e o modelo NARX para representar os modelos não lineares. Neste trabalho, escolhem-se esses modelos por serem bastante utilizados na literatura (Catumba et al., 2022; Santos et al., 2010). O modelo ARX é descrito por

$$y_k = a_1 y_{k-1} + \dots + a_p y_{k-p} + b_1 u_{k-1} + \dots + b_q u_{k-q} + e_k, \quad (1)$$

em que y_k é o sinal de saída, u_k é o sinal de entrada, $\theta^T = [a_1 \dots a_p \ b_1 \dots b_q]$ é o vetor de parâmetros, p e q são, respectivamente, a ordem dos termos autorregressivos da saída e entrada do modelo, e_k é o erro de modelagem.

Para o caso não linear, o modelo NARX pode ser descrito por

$$y_k = F^l [y_{k-1}, \dots, y_{k-n_y} \ u_{k-1}, \dots, u_{k-\tau_d}, \dots, u_{k-n_u}], \quad (2)$$

em que $F^l[\cdot]$ é uma função polinomial não linear de y_k e u_k a qual possui o grau de não linearidade l , n_y , τ_d e n_u são, respectivamente, o máximo atraso em relação aos dados de saída, o máximo atraso puro e o máximo atraso em relação aos dados de entrada.

A quantidade de termos candidatos para os modelos não lineares cresce rapidamente ao aumentar o grau de não linearidade, l , e com os máximos atrasos do sistema n_y e n_u . Dessa forma, é necessário tratar o agrupamento de termos e coeficientes de agrupamento que descrevam o sistema dinâmico. Assim, neste trabalho é utilizado o algoritmo de Golub-Householder (GH) (Golub and Van Loan, 2013),

algoritmo iterativo que quando utilizado em conjunto com a taxa de redução de erro (ERR) realiza a decomposição QR (matriz ortogonal Q , matriz triangular superior R) da matriz de regressores, de forma que a cada iteração é utilizada a taxa ERR para selecionar os termos de maior importância. A taxa da redução de erro pode ser expressa por

$$[ERR]_i = \frac{\hat{g}_i^2 \langle w_i, w_i \rangle}{\langle y, y \rangle}, \quad (3)$$

em que g é o parâmetro do regressor acrescentado ao modelo, w é a matriz de regressores do modelo, y é o vetor referente às saídas do sistema e $\langle \cdot, \cdot \rangle$ indica o produto interno. As etapas de decomposição utilizando as reflexões Householder são descritas com maior detalhe em (Golub and Van Loan, 2013). Assim, ao final do algoritmo GH é criada uma matriz Ψ contendo os regressores apresentados conforme a maior taxa ERR.

Por exemplo: dada uma matriz Ψ , em cada iteração é calculada a taxa ERR para cada uma de suas colunas. A coluna que apresenta o maior índice ERR troca de posição com a coluna da atual iteração e o atraso do regressor dessa coluna é armazenado em um vetor. Logo após é realizado a transformação Householder da matriz Ψ modificada na atual iteração. A transformação Householder é dada por

$$H = I - \beta v v^T \quad (4)$$

em que H é a matriz de Householder que realiza a transformação, I é a matriz identidade, v é o vetor que encontra o maior taxa ERR, v^T é a transposta de v e β é um escalar obtido em função de v (veja Aguirre (2004), pág. 676). Em seguida, é realizada a multiplicação matricial

$$H^{(1)} = H\Psi, \quad (5)$$

sendo Ψ atualizada por $H^{(1)}$ terminando a primeira iteração. A quantidade de iterações realizadas é igual à quantidade de termos candidatos. Ao final do algoritmo, tem-se um vetor referente ao atraso dos regressores que compõem o modelo ranqueados conforme a taxa ERR.

Determinação da estrutura do modelo A determinação da estrutura do modelo consiste em escolher a quantidade de termos u_{k-n_u} e y_{k-n_y} que serão incluídos no modelo. Para o sistema linear, a ordem do modelo ARX é definida pelos número de polos n_y , zeros n_u , e do atraso puro τ_d . Para o sistema não linear, o número de termos candidatos cresce rapidamente com o aumento do grau de não linearidade e dos máximos atrasos do sistema n_u e n_y . Existem várias técnicas na literatura para determinar o ordem do modelo como o critério HAN (Hannan and Quinn, 1979), Critério de Informação Akaike (AIC) (Akaike, 1974), Critério de Informação Bayesiano (BIC) (Schwarz, 1978). Neste trabalho, utiliza-se o critério AIC, por ser um método bastante utilizado na literatura para o problema de seleção do modelo. O AIC indica a redução da variação dos resíduos quando novos termos são incluídos no modelo. O AIC é dado por

$$AIC(n_\theta) = N \ln[\sigma_{erro}^2(n_\theta)] + 2n_\theta, \quad (6)$$

em que N é o número de dados, $\sigma_{erro}^2(n_\theta)$ é a variância dos resíduos e n_θ é o número de termos presentes no modelo.

Estimação dos parâmetros A estimação de parâmetros consiste em estimar os parâmetros do modelo que caracterizam o sistema. Várias técnicas são utilizadas na

literatura para à estimação de parâmetros, dentre estas o método clássico amplamente utilizado é o método de mínimos quadrados (MQ), que se resume na minimização da soma do quadrado das diferenças entre os dados e a saída estimada pelo modelo. Esse método pode ser descrito por

$$\hat{\theta}_{MQ} = (\Psi^T \Psi)^{-1} \Psi^T y, \quad (7)$$

em que $\hat{\theta}$ é um vetor de parâmetros estimados, Ψ é a matriz de regressores, Ψ^T a pseudoinversa de Ψ e y é o vetor de medições. Neste trabalho, utiliza-se o método MQ devido à facilidade de implementação e ao amplo uso na literatura (Aguirre, 2004).

Validação do modelo Finalizando o processo de identificação de sistemas, a última etapa consiste na validação do modelo identificado. A partir da etapa de validação, é possível verificar se o modelo identificado consegue descrever o comportamento da variável de interesse. Nesse trabalho, são utilizadas duas métricas: a simulação livre e o índice RMSE para quantificar a qualidade do modelo obtido. O processo de simulação livre (ou predição de infinitos passos à frente) é um modelo de validação que utiliza, inicialmente, as predições passadas para compor o vetor de regressores, $\psi_{yu,k-1}^Y$, de forma que seja possível continuar realizando o processo de predição utilizando no vetor de regressores, os valores das medições estimadas, $\hat{y}_k$. Por exemplo, considera-se que um determinado modelo tenha o seguinte vetor de regressores, $\psi_{yu,k-1}^Y$, relacionando os dados de entrada e saída como

$$\psi_{yu,k-1}^Y = [y_{k-1} \ y_{k-2} \ u_{k-1} \ u_{k-2}], \quad (8)$$

Para calcular a estimativa da medição no próximo instante de tempo, tem-se

$$\hat{y}_3 = \psi_{yu,k-1}^Y \hat{\theta} = [y_{k-1} \ y_{k-2} \ u_{k-1} \ u_{k-2}] \hat{\theta}, \quad (9)$$

em que $\hat{\theta}$ é o vetor de parâmetros do modelo. Dessa forma, na implementação da simulação livre, inclui-se a predição da medição anterior no vetor de regressores para obter a uma nova predição, por exemplo,

$$\hat{y}_{k-4} = \psi_{\hat{y}_{k-1},k-1}^Y \hat{\theta} = [\hat{y}_{k-3} \ y_{k-2} \ u_{k-3} \ u_{k-2}] \hat{\theta}, \quad (10)$$

$$\hat{y}_{k-5} = \psi_{\hat{y}_{k-2},k-1}^Y \hat{\theta} = [\hat{y}_{k-4} \ \hat{y}_{k-3} \ u_{k-4} \ u_{k-3}] \hat{\theta}. \quad (11)$$

Outra métrica utilizada para validar um modelo consiste em calcular o índice RMSE. O índice RMSE representa o valor médio quadrático do erro de predição do modelo normalizado pelo valor médio quadrático do erro de predição de um preditor trivial (Aguirre, 2004). O índice RMSE é dado por

$$RMSE = \frac{\sqrt{\sum_{k=1}^N (y_k - \hat{y}_k)^2}}{\sqrt{\sum_{k=1}^N (y_k - \bar{y})^2}}, \quad (12)$$

em que $\hat{y}_k$ é a simulação livre do sinal e $\bar{y}$ é o valor médio do sinal medido y_k , sendo que a média é calculada na janela de identificação. O valor do índice RMSE indica que o índice compara as predições do modelo com a média temporal do sinal. Assim, os valores menores do que a unidade indicam um melhor desempenho em relação ao preditor padrão considerado (média).

3. RESULTADOS

O protocolo experimental utiliza os equipamentos destacados na Figura 1. Os ensaios experimentais visam com-

Tabela 2. Amplitude máxima (a_{max}) e mínima (a_{min}) utilizada para gerar o sinal de referência em cada ponto de operação.

Ponto de operação (%)	75	60	45	30
a_{max}	70	65	60	55
a_{min}	40	40	40	40

preender o comportamento da variável de nível. Na configuração proposta todas as válvulas manuais e a válvula pneumática FY-31 estão completamente abertas. Dessa forma, o movimento do fluxo de água se inicia quando a bomba trifásica é acionada, deslocando o fluido desde o reservatório de água até o tanque de aquecimento. Quando o fluxo de água passa pelo dispositivo FIT-31 é realizada a medição dos dados de vazão de entrada enquanto que no tanque de aquecimento, o dispositivo LIT-31 realiza a medição dos dados de nível no tanque. O controle do sistema é realizado pelo computador que possui o software *Matlab* que utiliza o protocolo de Comunicação em Plataforma Aberta (OPC, do inglês, *Open Platform Communication*) para realizar a comunicação com a planta didática e seus componentes. Por meio dessa comunicação é gerado um sinal referência do software *Matlab* que é enviado para o inversor de frequência, fazendo com que a bomba trifásica reproduza um sinal de vazão de entrada com características similares ao sinal de referência. Neste trabalho, utiliza-se uma onda senoidal como sinal de referência. Esse sinal senoidal pode ser descrito como

$$y_k = V_{pp} \sin(2\pi f_0 dt) + \text{offset}, \quad (13)$$

em que V_{pp} é o valor de pico a pico, f_0 é a frequência de 40 pontos por período, dt é o período de amostragem e offset é o valor de offset adicionado ao sinal. Os valores desses parâmetros fixos são $f_0 = 0,005$ Hz e $dt = 5$ s.

Para determinar os valores de V_{pp} e offset do sinal referência (13), é necessário escolher as amplitudes máxima e mínima do sinal senoidal. Assim, a partir dos valores escolhidos, encontram-se

$$V_{pp} = \frac{a_{min} + a_{max}}{2}; \quad (14)$$

$$\text{offset} = \frac{a_{min} - a_{max}}{2}; \quad (15)$$

em que a_{min} e a_{max} são, respectivamente, a amplitude mínima e máxima do sinal senoidal. Neste trabalho, consideram-se quatro pontos de operação, sendo 75%, 60%, 45% e 30% do nível do tanque de aquecimento da planta didática SMAR, conforme mostrado na Figura 2b. Na Tabela 2 mostram-se os valores de amplitude máxima e mínima utilizados para gerar o sinal de referência (Figura 2a) para cada ponto de operação supracitado.

Neste trabalho, foram testados quatro pontos de operação. Por simplicidade, é apresentado apenas o ponto de operação de 45%, pois neste ponto de operação as representações lineares e não lineares apresentam os melhores resultados encontrados dentre todos os modelos obtidos. Vale destacar que os outros pontos de operação apresentam características similares durante o processo de modelagem matemática. Nas Figuras 3 e 4 apresentam-se, respectivamente, os sinais da vazão de entrada e os sinais do nível, destacado em azul os dados utilizados para realizar a modelagem do modelo e em vermelho os dados para validar o modelo identificado. Observa-se que ao relacionar




Figura 2. Dados de entrada e saída para os pontos de operação de 75% (vermelho), 60% (azul), 45% (verde) e 30% (magenta): a) Sinais de referência do sinal senoidal e b) Sinais da variável de nível.




Figura 3. Sinal de vazão de entrada para o ponto de operação de 45%: a) Dados modelagem e b) Dados Validação.

o sinal de entrada (Figura 3) com o sinal de saída (Figura 4) é possível evidenciar que a característica senoidal da vazão de entrada é transferida para a variável de nível. Ao observar o intervalo de tempo de 0 a 70 segundos percebe-se que o sinal de vazão de entrada alcança o primeiro pico, gerando um aumento do nível no tanque. Após esses 70 segundos, a vazão de entrada começa a oscilar entre 380 a 680 litros por hora, resultando em um aumento gradativo do nível de aproximadamente 40% até o nível máximo de 45% em estado estacionário.

3.1 Sistema Linear

Para representar o sistema de nível é empregado o modelo linear ARX (1) descrito por

$$y(k) = 9.30e^{-0.1}y(k-1) + 5.50e^{-0.3}u(k-1). \quad (16)$$

Na Figura 5 mostra-se o critério AIC gerado a partir dos dados de modelagem, utilizado para determinar a ordem do modelo. Quando a curva AIC é analisada deve-se atentar a observar o primeiro joelho da curva, sendo este o ponto onde o índice AIC deixa de ter uma mudança




Figura 4. Sinal da variável de nível para o ponto de operação de 45%: a) Dados modelagem e b) Dados Validação.




Figura 5. AIC para o ponto de operação de 45%.

significativa ao adicionar novos regressores, assim supõem-se que esse seja o ponto onde deve-se parar de inserir regressores. Dessa forma, a Figura 5 indica que a ordem do modelo linear, $p = q = 2$. Após alguns testes, observou-se que ao reduzir a ordem do modelo para $p = q = 1$, o modelo reduzido (16) ainda descreve a dinâmica do sistema.

Finalmente, para validar o modelo identificado (16) é utilizada a simulação livre e o índice RMSE. Inicialmente, na Figura 6 apresenta-se a simulação livre do sinal de nível no ponto de operação de 45%. Observa-se que no intervalo de tempo de 0 a 100 segundos a simulação livre (vermelho) e os dados de validação (preto) possuem o comportamento muito próximo, sendo este o intervalo em que a vazão de entrada leva até alcançar o primeiro pico. No intervalo de 100 a 220 segundos, observa-se a região em que as duas curvas mais divergem. Percebe-se que a simulação livre apresenta um aumento menos acentuado do nível em comparação com os dados de validação. Após os 300 segundos iniciais, a simulação livre se aproxima dos dados de validação mostrando que o modelo identificado descreve a variável de nível.




Figura 6. Comparação da simulação livre dos modelos: ARX (16) (vermelho) e NARX (17) (azul), e os dados de validação (preto).

3.2 Sistema Não Linear

Para representar o sistema de nível é empregado o modelo não linear NARX (2) descrito por

$$y(k) = 9.70e^{-01}y(k-1) + 8.53e^{-06}u(k-1)u(k-2) - 5.30e^{-05}y(k-1)u(k-1). \quad (17)$$

Para obter o modelo não linear, segue-se o mesmo procedimento de Identificação de sistemas para o modelo linear. Entretanto, para o caso não linear, na etapa de determinação da representação matemática é incorporado um método que possibilite a escolha dos termos candidatos que melhor representem a variável de nível. Neste trabalho, utiliza-se o algoritmo GH em conjunto com a taxa ERR para selecionar os regressores. Desta forma, foram selecionados os dois primeiros regressores que apresentaram a maior taxa ERR encontrados pelo algoritmo GH. Por fim, são estimados os parâmetros para o modelo não linear utilizando o método MQ, conforme mostrado em (17).

Para validar o modelo NARX (17) é utilizada a simulação livre e o índice RMSE. Na Figura 6 mostra-se a simulação livre do modelo NARX (17) (azul) que caracteriza o sinal de nível no ponto de operação de 45%. Destaca-se que o resultado obtido na simulação livre para o modelo NARX apresenta um comportamento similar ao modelo ARX. Na Figura 6, observa-se que no intervalo de tempo de 100 a 220 segundos, a simulação livre (azul) diverge dos dados de validação (preto). A partir do instante de tempo superior a 300 segundos, observa-se que a simulação livre do modelo NARX (azul) consegue descrever adequadamente o comportamento dinâmico do sistema.

Na Tabela 3, apresenta-se o índice RMSE dos modelos identificados utilizando diferentes regressores para os modelos ARX e NARX. Observa-se que o modelo NARX com três regressores apresenta o melhor desempenho em comparação com o modelo ARX, obtendo o índice RMSE de 0,197. Ao aumentar a quantidade de regressores, observa-se que o modelo ARX perde a capacidade de descrever o comportamento da variável de nível.

Tabela 3. Índice RMSE para os modelos ARX (16) e NARX (17).

Modelo	Número de Regressores	Modelos Estimados	Índices RMSE
ARX	1	$y_k = 9,30e^{-1}y_{k-1} + 5,55e^{-3}u_{k-1}$	0,216
	2	$y_k = 1,47y_{k-1} - 5,09e^{-1}y_{k-2} + 2,92e^{-3}u_{k-1}$	1,000
NARX	1	$y_k = 9,55e^{-1}y_{k-1} + 6,78e^{-6}u_{k-1}u_{k-2}$	0,318
	2	$y_k = 9,70e^{-1}y_{k-1} + 8,53e^{-6}u_{k-1}u_{k-2} - 5,30e^{-5}y_{k-1}u_{k-1}$	0,197

4. CONCLUSÃO

Neste trabalho, investigou-se o problema de modelagem matemática para descrever o comportamento da variável de nível do tanque da planta didática SMAR PD3-F. A metodologia deste trabalho utilizou técnicas de identificação de sistema para modelos do tipo caixa preta. Os resultados mostram que para ambos os modelos ARX (16) e NARX (17) ao utilizar dois regressores nos modelos foi possível representar a variável de nível.

O modelo ARX apresentou um índice RMSE de 0,216 ao utilizar dois regressores, porém ao utilizar três regressores o modelo perdeu por completo a capacidade descrever a variável de nível. Entretanto, considerando um cenário

linear, o modelo ARX torna-se uma possibilidade para representar a variável de nível.

O modelo NARX apresentou um melhor desempenho com um índice RMSE de 0,197 para um modelo com três regressores no sinal de entrada e saída. Entretanto, o modelo obtido com dois regressores alcançou um índice RMSE de 0,318. A partir dos resultados obtidos, conclui-se que para o protocolo experimental proposto utilizando o sinal senoidal, o modelo NARX identificado (17) descreve melhor o comportamento da variável de nível. Assim, o processo de identificação do tipo caixa preta mostra-se como um método promissor para a modelagem matemática de plantas didáticas industriais.

REFERÊNCIAS

- Aguirre, L.A. (2004). *Introdução à identificação de sistemas-Técnicas lineares e não-lineares aplicadas a sistemas reais*. Editora UFMG.
- Akaike, H. (1974). A new look at the statistical model identification. *IEEE Transactions on Automatic Control*, 19(6), 716-723.
- Catumba, B.D., Sobrinho, J.A.M., Freitas, A.d.O., Pinto, V.P., and Rodrigues, L.R. (2022). Utilização dos modelos lineares e não lineares para estimativa da curva de descarga da bateria de um quadrirotor. In *Congresso Brasileiro de Automática-CBA*, volume 3.
- Golub, G.H. and Van Loan, C.F. (2013). *Matrix computations*. JHU press.
- Hannan, E.J. and Quinn, B.G. (1979). The determination of the order of an autoregression. *Journal of the Royal Statistical Society: Series B (Methodological)*, 41(2), 190-195.
- Ljung, L. (1998). System identification. In *Signal analysis and prediction*, 163-173. Springer.
- Lopes, J.C.S., Kamila, P.R., Nathalie, M.P., Marlon, J., Carmo, R., Oliveira, L., Araújo Jr, O., and Rodrigues, J. (2012). Identificação de um sistema dinâmico assimétrico por redes neurais artificiais.
- Mombello, E.E., Portillo, Á., and Flórez, G.A.D. (2020). New state-space white-box transformer model for the calculation of electromagnetic transients. *IEEE Transactions on Power Delivery*, 36(5), 2615-2624.
- Murray, T. and Clarke, G.K. (1995). Black-box modeling of the subglacial water system. *Journal of Geophysical Research: Solid Earth*, 100(B6), 10231-10245.
- Pereira, A.P. and Munareto, S.D.S. (2019). Modelagem caixa cinza por analogia a um circuito rc. In *Congresso Brasileiro de Automática-CBA*, volume 1.
- Santos, A.P.L., Milagres, N., Campos, A., Margoti, L., Amaral, G., and Barroso, M. (2010). Aplicação de representações em blocos interconectados em identificação caixa-cinza de sistemas dinâmicos não lineares. In *XVIII Congresso Brasileiro de Automática*, 4224-4230.
- Schwarz, G. (1978). Estimating the dimension of a model. *The annals of statistics*, 461-464.
- Smr (2015). Plantas didáticas pd3-f: Manual de instruções, operação e manutenção: Plantas didáticas. 3 ed.
- Verly, A., do Carmo, F.H.P., de Paula, M.V., and Ricco, R.A. (2019). Identificação de modelos para uma planta de nível didática smar pd3-f. In *Congresso Brasileiro de Automática-CBA*, volume 1.